



# Table des matières

|                                                            |           |
|------------------------------------------------------------|-----------|
| <b>Introduction</b>                                        | <b>3</b>  |
| <b>1 Contexte, objectifs et données</b>                    | <b>4</b>  |
| 1.1 Sélection et analyse des datasets                      | 4         |
| 1.1.1 Telco Customer Churn                                 | 4         |
| 1.1.2 92k Call Center Scripts                              | 5         |
| 1.1.3 Bitext Customer Support Chatbot                      | 5         |
| <b>2 Architecture et processus de réalisation</b>          | <b>6</b>  |
| 2.1 Dossier data                                           | 6         |
| 2.2 Dossier src                                            | 6         |
| 2.3 Dossier scripts                                        | 7         |
| 2.4 Étapes du processus de réalisation                     | 7         |
| 2.4.1 Étape 1 : téléchargement ou placement du dataset     | 7         |
| 2.4.2 Étape 2 : préparation des données                    | 8         |
| 2.4.3 Étape 3 : analyse exploratoire                       | 8         |
| 2.5 Architecture MCP                                       | 9         |
| <b>3 Modèles de classification et génération</b>           | <b>11</b> |
| 3.1 Classificateur principal : TF-IDF + LogisticRegression | 11        |
| 3.2 Justification du choix                                 | 11        |
| 3.3 Variante Transformer                                   | 11        |
| 3.4 Choix du modèle Ollama                                 | 12        |
| <b>4 Agent, API et interface utilisateur</b>               | <b>13</b> |
| 4.1 API FastAPI                                            | 14        |
| 4.1.1 Endpoint /health                                     | 14        |
| 4.1.2 Endpoint /chat                                       | 14        |
| 4.1.3 Endpoint /intents                                    | 14        |
| 4.1.4 Gestion des sessions                                 | 14        |
| 4.2 Interface Streamlit                                    | 15        |
| 4.2.1 Fonctionnalités principales                          | 15        |
| 4.2.2 Seuil de confiance                                   | 16        |
| 4.2.3 Dashboard de session                                 | 16        |
| 4.2.4 Exemple de test                                      | 16        |
| <b>5 Dépendances et déploiement</b>                        | <b>21</b> |
| 5.1 requirements.txt                                       | 21        |
| 5.2 requirements_light.txt                                 | 21        |

|          |                                                 |           |
|----------|-------------------------------------------------|-----------|
| 5.3      | Déploiement . . . . .                           | 21        |
| 5.3.1    | Lancement local . . . . .                       | 21        |
| 5.3.2    | Mode sans Ollama . . . . .                      | 21        |
| 5.3.3    | Mode avec Ollama . . . . .                      | 22        |
| 5.3.4    | Docker . . . . .                                | 22        |
| <b>6</b> | <b>Évaluation, bilan et perspectives</b>        | <b>24</b> |
| 6.1      | Évaluation du classificateur . . . . .          | 24        |
| 6.2      | Tests fonctionnels . . . . .                    | 24        |
| 6.3      | Tests de cas limites . . . . .                  | 24        |
| 6.4      | État final d'avancement . . . . .               | 24        |
| 6.4.1    | Éléments finalisés . . . . .                    | 24        |
| 6.4.2    | Éléments partiellement réalisés . . . . .       | 25        |
| 6.5      | Limites actuelles . . . . .                     | 25        |
| 6.6      | Perspectives d'amélioration . . . . .           | 25        |
| 6.7      | Liste des captures d'écran à intégrer . . . . . | 26        |
|          | <b>Conclusion générale</b>                      | <b>27</b> |
|          | Résumé final . . . . .                          | 27        |

# Introduction

Ce rapport présente la finalisation du projet académique mini-projet **INEAgent MCP CRM Bitext**, un système conversationnel intelligent appliqué au domaine du support client et de la relation client. Le projet vise à concevoir un agent capable de comprendre un message utilisateur, d'identifier son intention, de router cette intention vers le bon outil métier, puis de produire une réponse adaptée. Il a été réalisé par les étudiants :

- BENABOU Hafsa,
- COMPAORE Moustapha,
- et DIALLO Mamadou Tahirou

Tous étudiants en 2eme année de cycle ingénieur Data à INPT.

L'objectif initial était de développer une solution agentique basée sur le **Model Context Protocol** (MCP), en combinant :

- un dataset CRM spécialisé ;
- un classificateur d'intentions ;
- des tools métier simulant des actions CRM ;
- une API FastAPI ;
- une interface utilisateur Streamlit ;
- un modèle local Ollama pour reformuler ou générer des réponses naturelles.

Le projet a évolué progressivement depuis une première phase de conception et d'expérimentation dans un notebook, jusqu'à une version structurée sous forme de projet Python modulaire, avec scripts, API, interface graphique et documentation.

# Chapitre 1

## Contexte, objectifs et données

Le contexte du projet est celui de l'automatisation intelligente du support client. Dans un service CRM, les utilisateurs peuvent exprimer plusieurs types de demandes :

- annuler une commande ;
- suivre une livraison ;
- demander une facture ;
- changer une adresse de livraison ;
- demander un remboursement ;
- contacter un agent humain ;
- vérifier les moyens de paiement ;
- déposer une réclamation.

L'objectif du projet est donc de mettre en place un agent capable de traiter ce type de messages de manière structurée.

|                                                                                                                                                                                                                                                                     |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <p>Message utilisateur</p> <ul style="list-style-type: none"><li>-&gt; Classification de l'intention</li><li>-&gt; Selection du tool MCP correspondant</li><li>-&gt; Execution du tool CRM</li><li>-&gt; Generation ou reformulation de la reponse finale</li></ul> |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|

Cette architecture permet de séparer clairement la compréhension du message, la décision métier, l'exécution d'une action CRM et la génération de réponse. Cette séparation rend le système plus modulaire, plus testable et plus facilement améliorable.

### 1.1 Sélection et analyse des datasets

Au début du projet, plusieurs datasets ont été analysés afin de choisir la source de données la plus adaptée à un agent CRM.

#### 1.1.1 Telco Customer Churn

Le dataset **Telco Customer Churn** contient environ 7 043 clients et 21 variables structurées. Il est pertinent pour des tâches de prédiction du churn, c'est-à-dire l'identification des clients susceptibles de quitter un service.

Son rôle potentiel dans le projet était d'alimenter un futur tool MCP de scoring client :

```
predict_churn(customer_id)
```

Ce dataset est utile pour enrichir le contexte CRM, mais il ne répond pas directement au besoin principal de classification d'intentions conversationnelles.

### 1.1.2 92k Call Center Scripts

Le dataset **92k Call Center Scripts** contient environ 91 706 transcripts réels de centres d'appels. Il offre une richesse conversationnelle importante et pourrait être utilisé pour construire une mémoire conversationnelle ou un système RAG.

Son rôle potentiel était de servir de corpus documentaire pour enrichir les réponses de l'agent. Cependant, sa structure est moins directement exploitable pour un pipeline simple de classification d'intentions.

### 1.1.3 Bitext Customer Support Chatbot

Le dataset **Bitext Customer Support Chatbot** contient environ 26 900 paires instruction/réponse, réparties en 27 intentions et 11 catégories.

Il a été retenu comme dataset principal parce qu'il est directement aligné avec le besoin du projet :

- classification d'intentions ;
- entraînement supervisé ;
- routage vers des actions CRM ;
- génération de réponses orientées support client.

Le dataset Bitext est donc devenu le pivot du projet.

# Chapitre 2

## Architecture et processus de réalisation

La solution finale repose sur une architecture modulaire organisée autour des composants suivants :

```
Dataset Bitext
  -> Preparation et nettoyage des donnees
  -> Classificateur d'intentions
  -> Mapping intent -> tool MCP
  -> Agent CRM
  -> API FastAPI
  -> Interface Streamlit
```

Le projet est structuré autour de plusieurs fichiers et dossiers :

```
data/
src/
scripts/
api.py
streamlit_app.py
requirements.txt
requirements_light.txt
Dockerfile
README.md
```

### 2.1 Dossier data

Le dossier `data/` contient le dataset source, les fichiers `train/validation/test`, les fichiers JSONL, le classificateur entraîné et éventuellement un modèle Transformer sauvegardé.

### 2.2 Dossier src

Le dossier `src/` contient le coeur logique du projet :

- `data.py` : chargement, nettoyage et préparation des données ;
- `classifier.py` : classificateur TF-IDF + LogisticRegression ;
- `transformer_classifier.py` : wrapper pour un modèle Transformer ;
- `mcp_mapping.py` : mapping des intentions vers les tools MCP ;

- `tools.py` : stubs fonctionnels des tools CRM ;
- `agent.py` : orchestration de l'agent CRM ;
- `ollama.py` : fonctions de connexion à Ollama ;
- `config.py` : configuration globale du projet.

### 2.3 Dossier scripts

Le dossier **scripts/** contient les scripts d'exécution :

- ```
— download_dataset.py;
— prepare_data.py;
— train_classifier.py;
— train_transformer_classifier.py;
— evaluate_classifier.py;
— demo_agent.py;
— check_ollama.py.
```

## 2.4 Étapes du processus de réalisation

### 2.4.1 Étape 1 : téléchargement ou placement du dataset

Une contribution importante a été l'ajout du script :

```
scripts/download_dataset.py
```

Ce script permet de télécharger automatiquement le dataset Bitext depuis Hugging Face :

```
load_dataset("bitext/Bitext-customer-support-llm-chatbot-training-dataset")
```

Le fichier est ensuite sauvegardé dans :

data/Bitext\_Sample\_Customer\_Support\_Training\_Dataset\_27K\_responses-v11\_1.csv

Cette étape améliore la reproductibilité du projet, car l'utilisateur n'a plus besoin de placer manuellement le fichier CSV dans le dossier `data/`.



## 2.4.2 Étape 2 : préparation des données

La préparation des données est réalisée avec :

```
scripts/prepare_data.py
```

Cette étape effectue plusieurs traitements :

- chargement du CSV Bitext ;
- remplacement des templates comme `{{Order Number}}` ou `{{Website URL}}` ;
- création de colonnes nettoyées ;
- split stratifié train/validation/test ;
- export des fichiers CSV ;
- génération des fichiers JSONL.



Les fichiers générés sont :


```
data/bitext_train.csv
data/bitext_val.csv
data/bitext_test.csv
data/bitext_train_formatted.jsonl
data/bitext_val_formatted.jsonl
```

```
(agent-mcp-crm-bitext) mrtids@fedora:~/Documents/my_projects/agent_mcp_crm_bitext$ pyth
on scripts/prepare_data.py
Train: 21497 exemples
Validation: 2687 exemples
Test: 2688 exemples
Fichiers crees dans data/: bitext_train.csv, bitext_val.csv, bitext_test.csv
Fichiers JSONL crees dans data/: bitext_train_formatted.jsonl, bitext_val_formatted.js
onl
(agent-mcp-crm-bitext) mrtids@fedora:~/Documents/my_projects/agent_mcp_crm_bitext$
```

## 2.4.3 Étape 3 : analyse exploratoire

L'analyse exploratoire a permis d'étudier la distribution des intentions, les catégories, les flags comportementaux, les longueurs de textes et les templates présents dans les messages.





## 2.5 Architecture MCP

Le projet repose sur un mapping explicite entre les intentions du dataset Bitext et des tools MCP. Ce mapping est défini dans :

```
src/mcp_mapping.py
```

Exemples :

```
cancel_order -> cancel_order(order_id)
track_order -> get_order_status(order_id)
change_shipping_address -> update_shipping_address(order_id, new_address)
get_refund -> process_refund(order_id, reason)
contact_human_agent -> escalate_to_human(reason)
```

Les tools sont implémentés dans :

```
src/tools.py
```

Ils sont actuellement simulés, mais fonctionnels. Ils retournent des dictionnaires Python représentant des réponses CRM.

```
src > mcp_mapping.py > ...
```

```
1 | """Mapping between Bitext intents and CRM MCP tools."""
2
3 INTENT_TO_TOOL = {
4     "cancel_order": {"tool": "cancel_order", "params": ["order_id"]},
5     "track_order": {"tool": "get_order_status", "params": ["order_id"]},
6     "change_order": {"tool": "modify_order", "params": ["order_id", "changes"]},
7     "place_order": {"tool": "create_order", "params": ["product_id", "quantity"]},
8     "delivery_options": {"tool": "get_delivery_options", "params": ["address"]},
9     "delivery_period": {"tool": "get_delivery_estimate", "params": ["order_id"]},
10    "change_shipping_address": {"tool": "update_shipping_address", "params": ["order_id", "new_address"]},
11    "get_refund": {"tool": "process_refund", "params": ["order_id", "reason"]},
12    "return": {"tool": "initiate_return", "params": ["order_id", "items"]},
13    "check_refund_policy": {"tool": "get_refund_policy", "params": []},
14    "create_account": {"tool": "create_account", "params": ["email", "name"]},
```

# Chapitre 3

## Modèles de classification et génération

### 3.1 Classificateur principal : TF-IDF + LogisticRegression

Le classificateur principal du projet repose sur :

```
TF-IDF + LogisticRegression
```

Il est implémenté dans :

```
src/classifier.py
```

Le pipeline utilise des unigrammes et bigrammes, un maximum de 10 000 features, une régression logistique et un entraînement supervisé sur la colonne **intent**.

Commande d'entraînement :

```
python scripts/train_classifier.py
```

Le modèle entraîné est sauvegardé dans :

```
data/intent_classifier.pkl
```

Ce choix est particulièrement adapté aux contraintes matérielles du projet, car il fonctionne efficacement sur CPU.

### 3.2 Justification du choix

Au départ, le projet envisageait un fine-tuning de modèle LLM, notamment avec QLoRA sur Qwen/Qwen2.5-3B-Instruct. Cependant, cette approche demande un GPU, comme une carte T4 sur Google Colab.

Or, l'environnement local disponible est principalement CPU. Le choix final a donc été d'utiliser **TF-IDF + LogisticRegression** pour la classification d'intentions, et de réserver Ollama à la reformulation de réponse.

### 3.3 Variante Transformer

Le projet intègre également une variante Transformer optionnelle. Les fichiers concernés sont :

```
src/transformer_classifier.py
scripts/train_transformer_classifier.py
```

Le modèle par défaut est :

```
google/bert_uncased_L-2_H-128_A-2
```

Il s'agit d'un mini-BERT léger, plus adapté au CPU qu'un grand modèle Transformer. Le script permet également d'utiliser DistilBERT :

```
python scripts/train_transformer_classifier.py --model-name distilbert-base-uncased
```

Cette variante est intéressante pour expérimenter avec des modèles deep learning, mais elle reste plus lourde que TF-IDF.

### 3.4 Choix du modèle Ollama

Le modèle Ollama recommandé dans la version finale est :

```
qwen2.5:1.5b
```

Ce choix a été fait car il représente un bon compromis entre qualité de génération et performance sur CPU.

La configuration se trouve dans :

```
src/config.py
```

avec :

```
DEFAULT_OLLAMA_MODEL = "qwen2.5:1.5b"
FALLBACK_OLLAMA_MODEL = "qwen2.5:1.5b"
```

Le rôle d'Ollama dans la solution finale n'est pas de classifier l'intention. La classification est assurée par TF-IDF ou Transformer. Ollama sert uniquement à produire ou reformuler une réponse plus naturelle.

```
success
● (agent-mcp-crm-bitext) mrtids@fedora:~/Documents/my_projects/agent_mcp_crm_bitext$ python scripts/check_ollama.py
Ollama est actif.
Modeles disponibles: ['qwen2.5:1.5b', 'llama3.2:1b', 'llama3.1:latest', 'nomic-embed-text:latest']
❖ (agent-mcp-crm-bitext) mrtids@fedora:~/Documents/my_projects/agent_mcp_crm_bitext$
```

# Chapitre 4

## Agent, API et interface utilisateur

La classe principale de l'agent est :

```
src/agent.py
```

Elle est représentée par :

```
CRMAgent
```

Son rôle est d'orchestrer tout le pipeline :

1. recevoir le message utilisateur ;
2. classifier l'intention ;
3. vérifier le score de confiance ;
4. appliquer un fallback vers un agent humain si la confiance est faible ;
5. exécuter le tool MCP correspondant ;
6. générer ou retourner une réponse ;
7. stocker l'historique de conversation.

```
on scripts/demo_agent.py
● (agent-mcp-crm-bitext) mrtids@fedora:~/Documents/my_projects/agent_mcp_crm_bitext$ pyth
on scripts/demo_agent.py
Utilisateur: I need to cancel my order #12345
Intent: cancel_order (87.0%)
Tool: cancel_order
Resultat tool: {'status': 'success', 'message': 'Commande #12345 annulee avec succes.'
, 'refund_delay': '5-10 jours ouvres'}
Reponse: Agent CRM : Je suis désolé d'entendre que vous avez besoin de rétracter votre
commande. Pourriez-vous me dire quel est le numéro de la commande #12345, s'il vous p
laît ?
-----
Utilisateur: Where is my package? I placed order ORD-67890 a week ago
Intent: contact_human_agent (23.0%)
Tool: escalate_to_human
Resultat tool: {'status': 'transferred', 'message': 'Vous allez etre mis en relation a
vec un agent humain.', 'reason': 'Where is my package? I placed order ORD-67890 a week
ago', 'wait_time': '~5 minutes'}
Reponse: Agent CRM : Je suis désolé d'entendre que vous avez besoin de récupérer votre
paquet. Pourriez-vous me dire quel est le numéro de la commande #67890, s'il vous pla
ît ?
```

## 4.1 API FastAPI

L'API est implémentée dans :

```
api.py
```

Elle expose plusieurs endpoints :

```
GET /health
POST /chat
DELETE /session/{session_id}
GET /intents
```

### 4.1.1 Endpoint /health

Cet endpoint permet de vérifier que l'API est active.

### 4.1.2 Endpoint /chat

Cet endpoint permet d'envoyer un message à l'agent CRM.

```
curl -X POST http://localhost:8000/chat ^
-H "Content-Type: application/json" ^
-d "{\"message\":\"I want to cancel my order number 12345\", \"session_id\":\"demo\"}"
```

### 4.1.3 Endpoint /intents

Cet endpoint permet de consulter la liste des intentions connues par le classificateur.

### 4.1.4 Gestion des sessions

L'API maintient des sessions en mémoire avec un dictionnaire Python. Cela permet de garder un historique conversationnel par session.

```
(agent-mcp-crm-bitext) mrtids@fedora:~/Documents/my_projects/agent_mcp_crm_bitext$ uvicorn api
:app --reload --port 8000
INFO: Will watch for changes in these directories: ['/home/mrtids/Documents/my_projects/ag
ent_mcp_crm_bitext']
INFO: Uvicorn running on http://127.0.0.1:8000 (Press CTRL+C to quit)
INFO: Started reloader process [62345] using WatchFiles
INFO: Started server process [62358]
INFO: Waiting for application startup.
INFO: Application startup complete.
```

```
main* 0↓ 1↑ 0 0 0
```

```

❖ (agent-mcp-crm-bitext) mrtids@fedora:~/Documents/my_projects/agent_mcp_crm_bitext$ uvicorn api
:app --reload --port 8000
INFO:      Will watch for changes in these directories: ['/home/mrtids/Documents/my_projects/ag
ent_mcp_crm_bitext']
INFO:      Uvicorn running on http://127.0.0.1:8000 (Press CTRL+C to quit)
INFO:      Started reloader process [62345] using WatchFiles
INFO:      Started server process [62358]
INFO:      Waiting for application startup.
INFO:      Application startup complete.
█

main* 0↻ 0↓ 1↑ 0⊗ 0⚠ 0
❖ (agent-mcp-crm-bitext) mrtids@fedora:~/Documents/my_projects/agent_mcp_crm_bitext$ uvicorn api
:app --reload --port 8000
INFO:      Will watch for changes in these directories: ['/home/mrtids/Documents/my_projects/ag
ent_mcp_crm_bitext']
INFO:      Uvicorn running on http://127.0.0.1:8000 (Press CTRL+C to quit)
INFO:      Started reloader process [62345] using WatchFiles
INFO:      Started server process [62358]
INFO:      Waiting for application startup.
INFO:      Application startup complete.
█

main* 0↻ 0↓ 1↑ 0⊗ 0⚠ 0
❖ (agent-mcp-crm-bitext) mrtids@fedora:~/Documents/my_projects/agent_mcp_crm_bitext$ uvicorn api
:app --reload --port 8000
INFO:      Will watch for changes in these directories: ['/home/mrtids/Documents/my_projects/ag
ent_mcp_crm_bitext']
INFO:      Uvicorn running on http://127.0.0.1:8000 (Press CTRL+C to quit)
INFO:      Started reloader process [62345] using WatchFiles
INFO:      Started server process [62358]
INFO:      Waiting for application startup.
INFO:      Application startup complete.
█

main* 0↻ 0↓ 1↑ 0⊗ 0⚠ 0

```

## 4.2 Interface Streamlit

Une contribution importante de finalisation a été l'ajout d'une interface utilisateur interactive avec Streamlit. Le fichier concerné est :

```
streamlit_app.py
```

Cette interface permet de rendre le système plus accessible, plus démontrable et plus compréhensible. Elle est connectée à l'API FastAPI et permet de tester le pipeline complet sans passer par la ligne de commande.

### 4.2.1 Fonctionnalités principales

L'interface permet :

- de configurer l'URL de l'API FastAPI ;
- de vérifier si l'API est connectée ;
- de consulter la liste des intents disponibles ;
- de saisir un message client personnalisé ;



- de sélectionner un exemple prédéfini ;
- d'envoyer le message à l'API ;
- d'afficher l'intention détectée ;
- d'afficher le score de confiance ;
- d'afficher le tool MCP appelé ;
- de consulter le résultat technique du tool ;
- de suivre l'historique des interactions ;
- d'exporter l'historique au format CSV.

### 4.2.2 Seuil de confiance

L'interface intègre un seuil de confiance configurable, fixé par défaut à 0.70. Si le score de confiance est inférieur à ce seuil, l'interface recommande une redirection vers un agent humain.

### 4.2.3 Dashboard de session


Un dashboard permet de suivre le nombre de messages analysés, la confiance moyenne, le nombre d'intentions détectées, le nombre de cas nécessitant une escalade, la répartition des intentions et l'historique technique.

### 4.2.4 Exemple de test

Un exemple de test concluant a été réalisé avec le message :

I want to cancel my order number 12345

Le système a détecté l'intention `cancel_order` et a appelé le tool `cancel_order`.



## Configuration


URL de l'API FastAPI

http://127.0.0.1:8000

Session ID

crm-session-9c790f2b

Seuil de confiance pour traitement automatique



API connectée

Timestamp : 2026-06-20T18:58:27.362825



Réinitialiser la session

Session réinitialisée



Tester l'exemple

Tu peux choisir un exemple ou écrire ton propre message client.

Message client personnalisé

Hi, I need to cancel my order but i don't remember the order id



Analyser le message



Nouveau test



Bonjour,

Je suis désolé d'apprendre que vous avez besoin de révoquer votre commande. Pourriez-vous s'il vous plaît me donner l'identifiant de votre commande, s'il vous plaît ? C'est essentiel pour pouvoir procéder à la réservation.

Merci beaucoup !

Cordialement,

[Votre nom]

Intent : cancel\_order

Confiance : 48.80%

Niveau : Faible

Tool MCP appelé : cancel\_order

⚠ Confiance faible : redirection recommandée vers un agent humain.

Voir le résultat technique du tool



Voir le résultat technique du tool



```
{
  "status" : "success"
  "message" : "Commande unknown annulee avec succes."
  "refund_delay" : "5-10 jours ouvres"
}
```



## Dashboard

Messages

1

Confiance moyenne

48.80%

Intents

1

Escalades

1

---

## Répartition des intents

cancel\_order — 1 message(s)



---

# Historique technique

message

Hi, I need to cancel my order but i don't remembe



Télécharger l'historique CSV

# Chapitre 5

## Dépendances et déploiement

Deux fichiers de dépendances sont disponibles.

### 5.1 requirements.txt

Ce fichier contient les dépendances complètes, notamment `pandas`, `matplotlib`, `seaborn`, `scikit-learn`, `fastapi`, `uvicorn`, `pydantic`, `langchain`, `langchain-ollama`, `datasets`, `transformers`, `torch` et `evaluate`.

### 5.2 requirements\_light.txt

Ce fichier contient une version plus légère pour l'API et l'interface Streamlit. Il est plus adapté aux machines à ressources limitées lorsqu'on ne souhaite pas entraîner de modèle Transformer.

### 5.3 Déploiement

#### 5.3.1 Lancement local

Pour lancer l'API :

```
uvicorn api:app --reload --port 8000
```

Pour lancer Streamlit :

```
streamlit run streamlit_app.py
```

#### 5.3.2 Mode sans Ollama

```
$env:CRM_AGENT_USE_OLLAMA="false"  
uvicorn api:app --reload --port 8000
```

### 5.3.3 Mode avec Ollama

```
ollama serve  
ollama pull qwen2.5:1.5b  
uvicorn api:app --reload --port 8000
```

### 5.3.4 Docker

```
docker build -t agent-crm .  
docker run -p 8000:8000 -e CRM_AGENT_USE_OLLAMA=false agent-crm
```

#### Capture 20 – Lancement FastAPI

Terminal de lancement de FastAPI.

*Emplacement réservé pour capture d'écran*

FIGURE 5.1 – Capture 20 – Lancement FastAPI

#### Capture 21 – Lancement Streamlit

Terminal de lancement de Streamlit.

*Emplacement réservé pour capture d'écran*

FIGURE 5.2 – Capture 21 – Lancement Streamlit

### **Capture 22 – Build Docker**

Commande `docker build`.

*Emplacement réservé pour capture d'écran*

FIGURE 5.3 – Capture 22 – Build Docker

### **Capture 23 – Conteneur Docker**

Commande `docker run`.

*Emplacement réservé pour capture d'écran*

FIGURE 5.4 – Capture 23 – Conteneur Docker



# Chapitre 6

## Évaluation, bilan et perspectives

### 6.1 Évaluation du classificateur

Le script :

```
scripts/evaluate_classifier.py
```

permet de calculer l'accuracy globale, la confiance moyenne, le ratio d'exemples avec confiance supérieure à 80%, un rapport de classification et une matrice de confusion.

### 6.2 Tests fonctionnels

Les tests fonctionnels portent sur la préparation des données, l'entraînement du classificateur, le chargement du modèle, l'appel des tools MCP, le fonctionnement de l'API, le fonctionnement de l'interface Streamlit, le routage correct des intents et la gestion des faibles scores de confiance.

### 6.3 Tests de cas limites

Les cas limites prévus incluent :

- message vide ;
- message très court ;
- faute de frappe ;
- intention multiple ;
- demande hors périmètre ;
- message agressif ;
- absence de numéro de commande.

### 6.4 État final d'avancement

#### 6.4.1 Éléments finalisés

- Le notebook initial a été transformé en projet Python modulaire.

- Le dataset Bitext est intégré dans un workflow reproductible.
- Le script de téléchargement du dataset a été ajouté.
- Les données peuvent être préparées automatiquement.
- Le classificateur TF-IDF est entraînable localement.
- Le modèle est sauvegardé dans `data/intent_classifier.pkl`.
- L'agent CRM est implémenté.
- Le mapping intent vers tool MCP est complet.
- Les tools MCP sont simulés et fonctionnels.
- L'API FastAPI est connectée au vrai agent.
- L'interface Streamlit est disponible.
- Ollama est configuré avec `qwen2.5:1.5b`.
- Le mode sans Ollama est disponible.
- Le mode Transformer optionnel est disponible.
- La documentation README a été structurée en étapes.

#### 6.4.2 Éléments partiellement réalisés

- Le fine-tuning complet d'un LLM avec QLoRA n'a pas été retenu pour l'exécution locale CPU.
- Le dataset Telco Churn n'a pas encore été intégré comme tool MCP.
- Les tools CRM restent des stubs, non connectés à un vrai système métier.
- Le modèle Transformer reste optionnel et expérimental.
- La persistance des sessions est en mémoire, sans Redis ou base de données.

### 6.5 Limites actuelles

Le projet reste perfectible sur plusieurs points :

- la classification peut être moins robuste sur des messages réels très ambigus ;
- les intentions multiples ne sont pas encore gérées ;
- l'extraction des paramètres repose sur des règles simples ;
- les tools MCP ne sont pas connectés à un vrai CRM ;
- la mémoire conversationnelle est limitée ;
- l'interface Streamlit pourrait encore exposer plus d'options de configuration.

### 6.6 Perspectives d'amélioration

Plusieurs pistes sont possibles pour faire évoluer le projet :

- intégrer le dataset Telco Churn ;
- ajouter un tool `predict_churn(customer_id)` ;
- améliorer l'extraction d'entités ;

- gérer les intentions multiples ;
- connecter les stubs MCP à un vrai backend CRM ;
- ajouter une persistance Redis ou SQLite ;
- améliorer l'interface Streamlit ;
- calibrer les seuils de confiance ;
- tester DistilBERT ou une architecture embeddings.

## 6.7 Liste des captures d'écran à intégrer

| Capture | Description                                                       |
|---------|-------------------------------------------------------------------|
| 1       | Téléchargement du dataset avec <code>download_dataset.py</code> . |
| 2       | Préparation des données avec <code>prepare_data.py</code> .       |
| 3       | Fichiers générés dans le dossier <code>data/</code> .             |
| 4       | Distribution des catégories et intentions.                        |
| 5       | Matrice de confusion.                                             |
| 6       | Entraînement du classificateur.                                   |
| 7       | Vérification Ollama.                                              |
| 8       | Démo agent en ligne de commande.                                  |
| 9       | Lancement FastAPI.                                                |
| 10      | Swagger FastAPI.                                                  |
| 11      | Test du endpoint <code>/chat</code> .                             |
| 12      | Interface Streamlit : accueil.                                    |
| 13      | Configuration API dans Streamlit.                                 |
| 14      | Test d'un message client.                                         |
| 15      | Résultat de classification.                                       |
| 16      | Tool MCP appelé.                                                  |
| 17      | Dashboard Streamlit.                                              |
| 18      | Historique technique.                                             |
| 19      | Export CSV.                                                       |
| 20      | Build Docker.                                                     |
| 21      | Conteneur Docker lancé.                                           |

# Conclusion générale

Le projet **Agent MCP CRM Bitext** a évolué d'un notebook expérimental vers une application modulaire complète. La solution finale permet de traiter des messages clients, de détecter leur intention, d'appeler un tool CRM correspondant, puis de produire une réponse exploitable.

La solution repose sur une architecture pragmatique adaptée aux ressources disponibles :

```
TF-IDF + LogisticRegression pour la classification
Tools MCP pour la logique metier
FastAPI pour l'exposition du service
Streamlit pour la demonstration interactive
Ollama qwen2.5:1.5b pour la reformulation optionnelle
```

Le projet atteint donc son objectif principal : démontrer un agent CRM intelligent, modulaire et fonctionnel, capable de combiner classification d'intentions, routage MCP et interaction utilisateur.

Les contributions finales ont permis de renforcer la reproductibilité, l'ergonomie et la démontrabilité du projet, notamment grâce au script de téléchargement automatique du dataset, à l'intégration d'un backend Transformer optionnel, au choix d'un modèle Ollama plus léger, à l'interface Streamlit, à la structuration complète du projet et à la documentation par étapes.

Même si certains points restent perfectibles, notamment l'intégration d'un vrai CRM et la gestion des intentions multiples, la version actuelle constitue une base solide pour une solution agentique CRM locale et extensible.

## Résumé final

Le projet finalisé peut être résumé ainsi :

```
Un agent CRM intelligent capable de :
- comprendre une demande client ;
- identifier son intention ;
- appeler un outil metier MCP ;
- retourner une reponse structuree ;
- etre teste via API ou interface Streamlit ;
- fonctionner sur CPU avec un modele léger.
```

La solution est adaptée aux contraintes matérielles du projet et reste évolutive pour de futures améliorations.